



Universidade do Minho
Escola de Ciências
Departamento de Matemática

Análise Numérica

ERROS E ESTABILIDADE NUMÉRICA

Maria Joana Soares & Maria Irene Falcão



INTRODUÇÃO

ANÁLISE NUMÉRICA

O uso de métodos numéricos, i.e. métodos que utilizam apenas um número finito de operações elementares da aritmética¹ e são, por isso especialmente adequados para utilização num computador, é hoje em dia indispensável nas mais diversas áreas das Ciências Aplicadas e Engenharia, como por exemplo:

- ▶ dinâmica de fluidos
- ▶ engenharia de estruturas
- ▶ meteorologia
- ▶ biologia
- ▶ medicina
- ▶ economia

A **Análise Numérica** é o ramo da Matemática que se dedica ao **desenvolvimento** e **análise** de métodos numéricos.

¹ Em oposição aos métodos analíticos, tais como a derivação, a integração, os quais envolvem processos limite.

ERRO DE TRUNCATURA

Exemplo: Calcular o valor de $\exp(0.125)$

Temos

$$\exp(0.125) = \lim_{n \rightarrow \infty} \left(1 + \frac{0.125}{n} \right)^n = ?$$

Uma possível solução *numérica* pode ser obtida usando os primeiros 8 termos da expansão de $\exp(x)$ em série de McLaurin:


$$\exp(0.125) \approx 1 + 0.125 + 0.125^2/2 + \cdots + 0.125^7/7! \approx 1.13315 .$$

Numérico $\neq$ Analítico $\implies$ *Erro de truncatura (ou de discretização)*

ERRO DE TRUNCATURA

Exemplo:

$$\int_a^b f(x) dx \approx \left(\frac{b-a}{2} \right) [f(a) + f(b)]$$



Regra do trapézio

$$E(f) = -\frac{(b-a)^3}{12} f''(\xi), \quad \xi \in [a, b]$$

- ➡ Muitos dos métodos numéricos estudados são muito antigos (*por exemplo, método de Newton para resolução de equações não lineares, método de Gauss para a resolução de sistemas de equações lineares, etc.*), mas vieram a assumir grande importância devido ao aparecimento e acessibilidade de computadores.²
- ➡ Podemos dizer que a *Análise Numérica* é o estudo dos métodos de resolução de problemas matemáticos usando computadores $\implies$ *Erros de arredondamento* (devidos à capacidade limitada de representação de números em computador).

²A própria designação *Análise Numérica* surge em 1946, no início da era do computador.

PROBLEMA COMPUTACIONAL

A resolução de um problema computacional envolve, em geral, quatro fases:

1. Formulação de um modelo matemático e recolha de dados
2. Escolha de um algoritmo adequado
3. Cálculos (num computador)
4. Análise dos resultados

A análise numérica preocupa-se, essencialmente, com a fase 2, i.e. com o desenvolvimento e análise de algoritmos numéricos.

► Questões típicas com se preocupa um *analista numérico*:

- Quão preciso é o método numérico escolhido?
- Tratando-se de um método iterativo, quão rápida é a sua convergência?
- Quantas operações aritméticas envolve?

ERROS

Ao resolver um problema, podem surgir muitas formas de erro:

1. erros humanos (“bugs”)
2. erros de modelação (simplificação e idealização do problema)
3. erros nos dados (medição de quantidades físicas)
4. **erros de truncatura** (aproximação de integrais, limites, etc.)
5. **erros de arredondamento** (arredondamento dos dados e arredondamento dos resultados das operações aritméticas, por trabalharmos num computador)

⇒ Na UC de Análise Numérica, interessam-nos especialmente os erros de truncatura e os erros de arredondamento.



ARITMÉTICA COMPUTACIONAL

REPRESENTAÇÃO DE REAIS EM PONTO FLUTUANTE

Representação normalizada de um número real $x \neq 0$ na base b

onde

$$x = (-1)^s (\underbrace{.d_1 d_2 d_3 \dots}_m)_b b^e$$

$m \rightarrow$ mantissa

$e \rightarrow$ expoente

- ▶ $b \in \mathbb{N}, b \geq 2$
- ▶ $s \in \{0, 1\}$
- ▶ $d_i \in \{0, \dots, b-1\}, d_1 \neq 0$
- ▶ $e \in \mathbb{Z}$
- ▶ $(.d_1 d_2 d_3 \dots)_b$ designa $d_1 b^{-1} + d_2 b^{-2} + d_3 b^{-3} + \dots$.

REPRESENTAÇÃO DE REAIS EM PONTO FLUTUANTE

Esta representação **existe sempre** e, se excluirmos representações em que todos os dígitos sejam, a partir de determinada ordem, iguais a $b - 1$ (por exemplo, na base $b = 10$, não consideramos a representação $.499999 \dots$ para o número 0.5), esta representação **é única**.

Exemplos

$$\begin{aligned} \Rightarrow -3.725 &= -0.3725 \times 10^1 \\ &= -(3 \times 10^{-1} + 7 \times 10^{-2} + 2 \times 10^{-3} + 5 \times 10^{-4}) \times 10^1. \end{aligned}$$

$$\begin{aligned} \Rightarrow (101.01)_2 &= (0.10101)_2 \times 2^3 \\ &= (1 \times 2^{-1} + 1 \times 2^{-3} + 1 \times 2^{-5}) \times 2^3. \end{aligned}$$

$$\Rightarrow 1/3 = 0.33333 \dots = \left(\sum_{k=1}^{\infty} 3 \times 10^{-k} \right) \times 10^0$$

SISTEMA DE NUMERAÇÃO DE MÁQUINA

Um sistema de numeração de ponto flutuante ou sistema de numeração de máquina

$\mathcal{F} = F(b, t, m, M)$ é caracterizado por quatro parâmetros:

- ▶ b - base;
- ▶ m - valor mínimo dos expoente;
- ▶ t - número de dígitos da mantissa;
- ▶ M - valor máximo do expoente.

Constituem o sistema $F(b, t, m, M)$, para além do número zero, todos os números que se puderem escrever na forma

$$(-1)^s \times (.d_1 d_2 \dots d_t)_b \times b^e,$$

onde $s \in \{0, 1\}$, $d_1, d_2, \dots, d_t \in \{0, 1, \dots, b-1\}$, $d_1 \neq 0$ e $e \in \mathbb{Z}$ com $m \leq e \leq M$.

Números normalizados e desnormalizados

- ➡ Os números atrás referidos são os chamados números de máquina **normais** ou **normalizados**.
- ➡ O sistema de numeração $F(b, t, m, M)$ pode ainda admitir os chamados números **desnormalizados** ou **subnormais**, que são os números (não nulos) que se podem escrever na forma

$$(-1)^s \times (. \textcolor{red}{0} d_2 d_3 \dots d_t)_b \times b^{\textcolor{brown}{m}}.$$

Se nada for dito em contrário, quando nos referirmos a um sistema $F(b, t, m, M)$, consideramos apenas os números normalizados.

Nível de overflow e nível underflow

- ➡ O maior número de $F(b, t, m, M)$ é

$$\Omega := (1 - b^{-t})b^M,$$

e é chamado **nível de overflow**.

- ➡ O menor número positivo (normalizado) de $F(b, t, m, M)$ é dado por

$$\omega := b^{m-1}$$

e é chamado **nível de underflow**.

O menor número positivo de um sistema que admita números desnormalizados é b^{m-t} .

Conjunto dos representáveis

Ao conjunto

$$R_{\mathcal{F}} := [-\Omega, -\omega] \cup \{0\} \cup [\omega, \Omega]$$

chamamos **conjunto dos números representáveis**.

Os números de $R_{\mathcal{F}}$ são os números de grandeza aceitável (isto é, nem demasiado grandes nem demasiado pequenos em valor absoluto) para serem “representados” por números de máquina (da forma que iremos descrever de seguida); números fora desse conjunto terão tratamento especial.

De uma **forma simplificada**, vamos dizer que:

- ▶ um número real x tal que $|x| > \Omega$ origina *overflow*
- ▶ um número real x tal que $0 < |x| < \omega$ conduz a *underflow*.

Trata-se de uma simplificação daquilo que se poderá passar na realidade; por exemplo, números tais que $|x| < \omega$ poderão ser “substituídos” por números desnormalizados ou por zero e alguns números tais que $|x| > \Omega$ poderão ser representados por Ω (ou por $-\Omega$).

Note-se que $\mathcal{F} \subsetneq R_{\mathcal{F}}$. Mais precisamente, os números de máquina constituem um **subconjunto finito** do conjunto dos números representáveis.

Exemplo: No sistema $\mathcal{F} = F(10, 4, -99, 99)$

- ➡ $\Omega = (1 - 10^{-4}) \times 10^{99} = 0.9999 \times 10^{99}$
- ➡ $\omega = 0.1 \times 10^{-99} = 10^{-99-1} = 10^{-100}$
- ➡ $R_{\mathcal{F}} = [-0.9999 \times 10^{99}, -10^{-100}] \cup \{0\} \cup [10^{-100}, 0.9999 \times 10^{99}]$
- ➡ $\pi \in R_{\mathcal{F}}$, mas $\pi \notin \mathcal{F}$, já que $\pi = 3.141592654\dots$ não pode escrever-se com uma mantissa de apenas quatro dígitos.
- ➡ $10^{100} \notin R_{\mathcal{F}}$ ($\rightarrow$ *overflow*)
- ➡ $10^{-101} \notin R_{\mathcal{F}}$ ($\rightarrow$ *underflow*)

ARREDONDAMENTO

Dado um número $x \in R_{\mathcal{F}}$, será necessário encontrar um número de máquina que o represente. É natural exigir-se que esse número, que designaremos por $\text{fl}(x)$, esteja à menor distância possível de x , isto é, que satisfaça

$$|\text{fl}(x) - x| \leq |y - x|, \forall y \in F, \quad (1)$$

havendo uma regra para decidir o que fazer, no caso de empate. Quando $\text{fl}(x)$ é escolhido satisfazendo (1), dizemos que é usado **arredondamento para o mais próximo**.

Naturalmente, se $x \in F$, tem-se $\text{fl}(x) = x$, como seria de desejar.

No caso em que existam dois números de máquina à mesma distância do número x , é habitual (sobretudo se a base do sistema for 2 ou 10) usar-se o chamado **arredondamento para par**, em que se escolhe para $\text{fl}(x)$ aquele **cujo último dígito da mantissa seja par**.

ARREDONDAMENTO (CONT.)

Convenção

Neste curso, quando referirmos arredondamento, será sempre entendido como arredondamento para o mais próximo. Ao efetuarmos os nossos cálculos “à mão”, por simplicidade, usaremos o arredondamento habitual, isto é, arredondamento da mantissa para cima, no caso de empate (o que equivale a somar à mantissa $\frac{1}{2}bb^{-(t+1)}$, truncando, em seguida, o resultado para t dígitos); no entanto, devemos saber que a regra do arredondamento para par é a usada, por defeito, quando fazemos os cálculos no Matlab.

Nota: Existem outras formas de determinar $\text{fl}(x)$, como, por exemplo, a chamada truncatura, em que simplesmente se ignoram todos os dígitos da mantissa do número que estejam para além da posição t .

Exemplos

➡ Em $\mathcal{F} = F(10, 4, -2, 3)$

- ▶ $\text{fl}(.75824 \times 10^{-2}) = .7582 \times 10^{-2}$
- ▶ $\text{fl}(.75826 \times 10^{-2}) = .7583 \times 10^{-2}$
- ▶ $\text{fl}(.75825 \times 10^{-2}) = .7582 \times 10^{-2}$ (arredondamento para par)
- ▶ $\text{fl}(.75825 \times 10^{-2}) = .7583 \times 10^{-2}$ (arredondamento usual)
- ▶ $\text{fl}(.758251 \times 10^{-2}) = .7583 \times 10^{-2}$ (arredondamento para par)
- ▶ $\text{fl}(.758251 \times 10^{-2}) = .7583 \times 10^{-2}$ (arredondamento usual)

➡ Em $\mathcal{F} = F(2, 4, -2, 3)$

- ▶ $\text{fl}(.10110 \times 2^{-2}) = .1011 \times 2^{-2}$
- ▶ $\text{fl}(.10111 \times 2^{-2}) = .1100 \times 2^{-2}$

Seja $\mathcal{F} = F(b, t, m, M)$ um sistema de numeração de máquina.

Se $x \in R_{\mathcal{F}}$ tiver um expoente e na notação normalizada, então

$$|\text{fl}(x) - x| \leq \frac{1}{2} b b^{-(t+1)} b^e = \frac{1}{2} b^{-t} b^e. \quad (2)$$

Epsilon da máquina

Chama-se **epsilon da máquina**, e denota-se por ε , a diferença entre o número de máquina imediatamente superior a 1 e o número 1, isto é,

$$\varepsilon := b^{1-t}.$$

Unidade de erro de arredondamento

A **unidade de erro de arredondamento** é definida como

$$\mu := \frac{1}{2} b^{1-t} = \frac{1}{2} \varepsilon.$$

OPERAÇÕES DE VÍRGULA FLUTUANTE

Representaremos as operações de vírgula flutuante ou operações de máquina pelo símbolo usual rodeado por $\bigcirc$; por exemplo, $\bigoplus$, $\bigotimes$.

Admitimos que o resultado de uma operação de vírgula flutuante é obtido por arredondamento do resultado da operação exata³, isto é,

$$x \bigoplus y = \text{fl}(x + y), \quad x \bigotimes y = \text{fl}(x \times y), \quad \text{etc.}$$

No entanto, o resultado de duas ou mais operações aritméticas de ponto flutuante pode não corresponder ao arredondamento do correspondente valor exato, isto é, por exemplo $x \bigoplus (y \bigoplus z)$ não é necessariamente igual a $\text{fl}(x + (y + z))$.

³Supondo que resultado da operação exata não conduz nem a *overflow* nem a *underflow*.

OPERAÇÕES DE VÍRGULA FLUTUANTE (CONT.)

É importante ter em atenção que as operações de ponto flutuante **não satisfazem todas as propriedades usuais** das correspondentes operações em $\mathbb{R}$. Por exemplo, a adição não é associativa, não é válida a distributividade da multiplicação em relação à adição, etc.

Exemplo: Sejam $\mathcal{F} := F(10, 4, -99, 99)$ e $x = 0.5289$, $y = 0.8012$ e $z = 0.6024$.

⇒ $x \oplus (y \oplus z) = 0.1933 \times 10^1$

⇒ $(x \oplus y) \oplus z = 0.1932 \times 10^1$

!!!

SISTEMA DE NUMERAÇÃO DO MATLAB

Descrevemos agora, de forma breve, o sistema de numeração e tipo de arredondamento que estão definidos, **por defeito**, quando usamos o Matlab .

- ▶ O sistema de numeração usado é o sistema $F(2, 53, -1021, 1024)$.⁴ Assim, temos:

$$\Rightarrow \Omega = (1 - 2^{-53})2^{1024} = 2^{1024} - 2^{971} \approx 1.8 \times 10^{308} \quad (\text{realmax})$$

$$\Rightarrow \omega = 2^{-1022} \approx 2.2 \times 10^{-308} \quad (\text{realmin})$$

$$\Rightarrow \varepsilon = 2^{-52} \approx 2.2 \times 10^{-16} \quad (\text{eps})$$

$$\Rightarrow \mu = 2^{-53} \approx 1.1 \times 10^{-16}$$

- ▶ O sistema admite números desnormalizados, ou seja, números da forma

$$(-1)^s \times (.0 d_2 \cdots d_{53})_2 \times 2^{-1021}$$

O menor número positivo do sistema é, portanto

$$2^{-1021} \times 2^{-53} = 2^{-1074} \approx 4.9 \times 10^{-324}$$

⁴Este corresponde ao sistema de formato duplo (bin64) especificado pela chamada “norma IEEE 754”.

SISTEMA DE NUMERAÇÃO DO MATLAB (CONT.)

- O sistema de numeração tem ainda os “números” especiais

`Inf` `e` `- Inf` $(+\infty$ e $-\infty)$

para representar, por exemplo, o resultado da divisão de um número (não nulo) por zero, bem como o símbolo especial

`NaN` (Not a Number)

para representar o resultado de operações não definidas matematicamente, tais como $0/0$, $\infty - \infty$, etc.

- **Arredondamento** Dado $x \in \mathbb{R}$, $\text{fl}(x)$ é o número de máquina – normalizado ou desnormalizado – que lhe está mais próximo, com **arredondamento para par**, no caso de empate; exceptuam-se os números x tais que $|x| \geq (1 - 2^{-54})2^{1024}$, para os quais se tem $\text{fl}(x) = \text{Inf}$, se $x > 0$, ou $\text{fl}(x) = -\text{Inf}$, se $x < 0$.



FUNÇÕES DO MATLAB

dec2bin dec2hex dec2base bin2dec hex2dec base2dec

realmax realmin eps Inf NaN

ceil fix floor round



ERROS

ERRO ABSOLUTO E ERRO RELATIVO DE UM VALOR APROXIMADO

Sejam x um dado número e $\tilde{x}$ um valor aproximado para x .

Erro absoluto

A $E_{\tilde{x}} := x - \tilde{x}$ chamamos **erro (absoluto)** do valor aproximado $\tilde{x}$ para x .

Erro relativo

Se $x \neq 0$, a $R_{\tilde{x}} := \frac{x - \tilde{x}}{x}$ chamamos **erro relativo** do valor aproximado $\tilde{x}$ para x .

Exemplo: Sejam $x = 1/3, y = 1/3000, \tilde{x} = 0.3333, \tilde{y} = 0.0003$. Então

$$E_{\tilde{x}} = E_{\tilde{y}} = 0.00003333 \dots, R_{\tilde{x}} = 10^{-4}, R_{\tilde{y}} = 10^{-1}.$$

→ O erro relativo tem “mais informação” do que o erro absoluto.

NOTAS

- ➡ Na prática, é frequente estarmos apenas interessados no **valor absoluto** dos erros absoluto e relativo, continuando a designá-los pelos mesmos nomes, desde que tal seja claro pelo contexto.
- ➡ Como, na definição de erro relativo, o valor de x não é conhecido, é usual considerar-se a estimativa

$$|R_{\tilde{x}}| \approx \frac{|x - \tilde{x}|}{|\tilde{x}|}$$

- ➡ É frequente expressar-se o (valor absoluto) do erro relativo em percentagem; por exemplo, se $|R_{\tilde{x}}| = 0.05$, dizemos que $\tilde{x}$ tem um erro relativo de 5%.
- ➡ Da definição de erro relativo, obtém-se de imediato

$$\tilde{x} = x(1 - R_{\tilde{x}})$$

Erro relativo de arredondamento

Num sistema $F(b, t, m, M)$, dado um número $x \in R_F, x \neq 0$, tem-se (cf. fórmula(2))

$$|R_{fl(x)}| = \frac{|x - fl(x)|}{|x|} \leq \frac{\frac{1}{2}b^{-t}b^e}{b^{-1}b^e} = \frac{1}{2}b^{1-t} = \mu.$$

- ▶ O erro relativo cometido ao arredondar um número (representável) para um número de máquina é majorado pela unidade de erro de arredondamento da máquina.
- ▶ $fl(x) = x(1 + \delta), \quad |\delta| \leq \mu$



No Matlab, tem-se

$$|R_{fl(x)}| \leq 2^{-53} \approx 0.11 \times 10^{-15}$$

PROPAGAÇÃO DE ERROS NAS OPERAÇÕES USUAIS

Sejam $\tilde{x}$ e $\tilde{y}$ valores aproximados para x e y , respetivamente ($x, y \neq 0$), e sejam $S = x + y$, $P = x \times y$ e $Q = x/y$. Sejam $\tilde{S}$, $\tilde{P}$ e $\tilde{Q}$ os valores aproximados para S , P e Q obtidos usando os valores $\tilde{x}$ e $\tilde{y}$ em vez de x e y e admitindo que as operações são efetuadas exatamente. Podem estabelecer-se facilmente os seguintes resultados:

$$E_{\tilde{S}} = E_{\tilde{x}} + E_{\tilde{y}}$$

$$E_{\tilde{P}} = E_{\tilde{x}}y + E_{\tilde{y}}x - E_{\tilde{x}}E_{\tilde{y}}$$

$$E_{\tilde{Q}} = \frac{yE_{\tilde{x}} - xE_{\tilde{y}}}{y\tilde{y}}$$

$$R_{\tilde{S}} = \frac{x}{x+y}R_{\tilde{x}} + \frac{y}{x+y}R_{\tilde{y}}$$

$$R_{\tilde{P}} = R_{\tilde{x}} + R_{\tilde{y}} - R_{\tilde{x}}R_{\tilde{y}}$$

$$R_{\tilde{Q}} = \frac{R_{\tilde{x}} - R_{\tilde{y}}}{1 - R_{\tilde{y}}}$$

Se $|R_{\tilde{x}}|, |R_{\tilde{y}}| \ll 1$, então $R_{\tilde{P}} \approx R_{\tilde{x}} + R_{\tilde{y}}$ $R_{\tilde{Q}} \approx R_{\tilde{x}} - R_{\tilde{y}}$

A operações mais “perigosa” (isto é, que pode amplificar significativamente o erro relativo dos argumentos) é a divisão. Em que caso?

ALGORISMOS SIGNIFICATIVOS/CASAS DECIMAIS DE PRECISÃO

Seja $x = (-1)^s \times m_x \times 10^e$ um dado número (escrito na notação normalizada no sistema decimal) e seja $\tilde{x}$ uma sua aproximação.

- ➡ Diz-se que $\tilde{x}$ é uma aproximação para x com precisão de p casas decimais (c.d.) ou que $\tilde{x}$ aproxima x com p casas decimais (corretas), se p é o maior inteiro (positivo) tal que

$$|x - \tilde{x}| \leq 0.5 \times 10^{-p}$$

- ➡ Diz-se que $\tilde{x}$ é uma aproximação para x com precisão de q algarismos significativos (a.s) ou que $\tilde{x}$ aproxima x com q algarismos significativos (corretos)^a, se q é o maior inteiro (positivo) tal que

$$|x - \tilde{x}| \leq 0.5 \times 10^{-q} \times 10^e.$$

^aAssumimos aqui que $\tilde{x}$ tem, na notação normalizada, o mesmo expoente que x .

Exemplos

$$\Rightarrow x = 3.127, \tilde{x} = 3.123 \quad e = 1$$

$$|x - \tilde{x}| = 0.4 \times 10^{-2} < 0.5 \times 10^{-2} = 0.5 \times 10^{1-3}$$

2 c.d.

3 a.s.

$$\Rightarrow x = 0.0003127, \tilde{x} = 0.0003123 \quad e = -3$$

$$|x - \tilde{x}| = 0.4 \times 10^{-6} < 0.5 \times 10^{-6} = 0.5 \times 10^{-3-3}$$

6 c.d.

3 a.s.

$$\Rightarrow x = 3.127, \tilde{x} = 3.12 \quad e = 1$$

$$|x - \tilde{x}| = 0.7 \times 10^{-2} < 0.5 \times 10^{-1} = 0.5 \times 10^{1-2}$$

1 c.d.

2 a.s.

$$\Rightarrow x = 3.127, \tilde{x} = 3.13 \quad e = 1$$

$$|x - \tilde{x}| = 0.3 \times 10^{-2} < 0.5 \times 10^{-2} = 0.5 \times 10^{1-3}$$

2 c.d.

3 a.s.

Se $\tilde{x}$ é uma aproximação para x com p c.d. corretas, e x tem expoente e na notação normalizada, então $\tilde{x}$ tem precisão de $q = p + e$ a.s.^a

^aSupondo que $q = p + e > 0$ e que o expoente de $\tilde{x}$ na notação normalizada é também e .

ALGORISMOS SIGNIFICATIVOS/ERRO RELATIVO

- ▶ O número de **casas decimais** corretas está ligado ao **erro absoluto**.
- ▶ O número de **algarismos significativos** corretos está relacionado com o **erro relativo**. Com efeito:

- ▶ Se $|R_{\tilde{x}}| \leq 0.5 \times 10^{-q}$, então $\tilde{x}$ tem q a.s. corretos, pois

$$\left| \frac{x - \tilde{x}}{x} \right| \leq 0.5 \times 10^{-q} \Rightarrow |x - \tilde{x}| \leq 0.5 \times 10^{-q} |m_x 10^e| < 0.5 \times 10^{-q} \times 10^e$$

- ▶ Se $\tilde{x}$ é uma aproximação para x com q a.s. corretos, então

$$|R_{\tilde{x}}| = \left| \frac{x - \tilde{x}}{x} \right| \leq \frac{0.5 \times 10^{-q} \times 10^e}{|x|} \leq \frac{0.5 \times 10^{-q} \times 10^e}{0.1 \times 10^e} = 0.5 \times 10^{1-q}$$



No Matlab dado $x \in R_{\mathcal{F}}$, tem-se

$$|R_{\text{fl}(x)}| \leq 2^{-53} \approx 1.1 \times 10^{-16} < 0.5 \times 10^{-15}$$

Logo, $\text{fl}(x)$ tem (no mínimo) precisão de **15 algarismos significativos**.



CONDICIONAMENTO E ESTABILIDADE

CANCELAMENTO SUBTRATIVO

$$\Rightarrow x = 0.76545424 \times 10^1, \quad y = 0.76544199 \times 10^1$$

$$\Rightarrow \tilde{x} = 0.76545421 \times 10^1, \quad \tilde{y} = 0.76544200 \times 10^1$$

$\tilde{x}$ aproxima x com 7 a.s.; $\tilde{y}$ aproxima y com 7 a.s.

$$\Rightarrow z = x - y = 0.1225 \times 10^{-3}; \quad \tilde{z} = \tilde{x} - \tilde{y} = 0.1221 \times 10^{-3}$$

$\tilde{z}$ aproxima z com 3 algarismos significativos!

Erro relativo em $\tilde{z}$ pode ser 10 000 superior aos erros relativos em $\tilde{x}$ e $\tilde{y}$.

Cancelamento Subtrativo - Perda de algarismos significativos de precisão que resulta da subtração de números muito próximos. O erro relativo do resultado é muito maior que o erro relativo dos dados. **X**

Exemplo: $f(x) = \sqrt{x+1} - \sqrt{x}$ ou $g(x) = \frac{1}{\sqrt{x+1} + \sqrt{x}}$?



x	$f(x)$	$g(x)$
10^1	$1.5434713018702029 \times 10^{-1}$	$1.5434713018702051 \times 10^{-1}$
10^2	$4.9875621120889946 \times 10^{-2}$	$4.9875621120890272 \times 10^{-2}$
10^3	$1.5807437428957627 \times 10^{-2}$	$1.5807437428955823 \times 10^{-2}$
10^4	$4.9998750062485442 \times 10^{-3}$	$4.9998750062496093 \times 10^{-3}$
10^5	$1.5811348772558631 \times 10^{-3}$	$1.5811348772568783 \times 10^{-3}$
10^6	$4.9999987504634191 \times 10^{-4}$	$4.9999987500006253 \times 10^{-4}$
10^7	$1.5811387902431306 \times 10^{-4}$	$1.5811387905557208 \times 10^{-4}$
10^8	$5.0000000555883162 \times 10^{-5}$	$4.9999999874999996 \times 10^{-5}$
10^9	$1.5811390767339617 \times 10^{-5}$	$1.5811388296889049 \times 10^{-5}$
10^{10}	$4.9999944167211652 \times 10^{-6}$	$4.999999998750004 \times 10^{-6}$

cancelamento subtrativo ✗ todos algarismos significativos ✓

CONDICIONAMENTO/ESTABILIDADE

Em Análise Numérica existem duas questões fundamentais que devemos considerar quando resolvemos um problema:

1. Quão sensível é a solução à forma específica do problema em causa?

Bom/mau condicionamento do problema

2. Quão sensível é o algoritmo que estamos a usar à precisão dos dados?

Estabilidade/instabilidade do algoritmo

CONDICIONAMENTO DE UM PROBLEMA

Exemplo: [Sistema Linear]

Considere-se o problema da resolução do seguinte sistema de equações

$$\begin{cases} 1.01x + 0.99y = 2.00 \\ 0.99x + 1.01y = 2.00 \end{cases} \quad \text{Sol : } x = 1; y = 1.$$

Modifiquemos ligeiramente o lado direito:

$$\begin{cases} 1.01x + 0.99y = 2.02 \\ 0.99x + 1.01y = 1.98 \end{cases} \quad \text{Sol : } x = 2; y = 0.$$

$$\begin{cases} 1.01x + 0.99y = 1.98 \\ 0.99x + 1.01y = 2.02 \end{cases} \quad \text{Sol : } x = 0; y = 2.$$

“Pequenas” alterações nos dados $\implies$ “grandes alterações” nas soluções

Problema mal condicionado!

Interpretação geométrica




Figura: Representação gráfica dos três sistemas

Exemplo: [Polinómio de Wilkinson] $p(x) = (x - 1)(x - 2) \dots (x - 20)$

$$p(x) = x^{20} - 210x^{19} + 20615x^{18} - 1256850x^{17} + \dots + 20!$$

Seja q o polinómio que resulta de p , modificando o coeficiente de x^{19} :

$$q(x) = x^{20} - (210 + 2^{-23})x^{19} + 20615x^{18} - 1256850x^{17} + \dots + 20!$$

As raízes destes polinómios obtidas usando o Mathematica  (precisão *infinita*) e o Matlab  estão na tabela da página seguinte.

- ➡ Os resultados obtidos pelo Matlab no cálculo das raízes do polinómio p , mostram como estas são extremamente sensíveis ao efeito dos erros de arredondamento.
- ➡ Uma perturbação relativa de $2^{-23}/210 \approx 5.7 \times 10^{-10}$ no coeficiente a_{19} de p provoca uma alteração muito grande nas raízes. Metade delas “tornam-se” complexas.

Problema mal condicionado!

 	 
1	1.0000
2	2.0000
3	3.0000
4	4.0000
5	5.0000
6	6.0000
7	7.0000
8	8.0003
9	8.9984
10	10.0061
11	10.9840
12	12.0334
13	12.9491
14	14.0653
15	14.9354
16	16.0483
17	16.9711
18	18.0112
19	18.9972
20	20.0003
1.0000	1.0000 + 0.0000i
2.0000	2.0000 + 0.0000i
3.0000	3.0000 + 0.0000i
4.0000	4.0000 + 0.0000i
5.0000	5.0000 + 0.0000i
6.0000	6.0000 + 0.0000i
6.9997	6.9994 + 0.0000i
8.0073	8.0153 + 0.0000i
8.91725	8.8533 + 0.0000i
10.0953 - 0.6435i	9.9859 - 0.8088i
10.0953 + 0.6435i	9.9859 + 0.8088i
11.7936 - 1.6523i	11.6820 - 1.8654i
11.7936 + 1.6523i	11.6820 + 1.8654i
13.9924 - 2.5188i	13.9142 - 2.7966i
13.9924 + 2.5188i	13.9142 + 2.7966i
16.7307 - 2.8126i	16.7521 - 3.1418i
16.7307 + 2.8126i	16.7521 + 3.1418i
19.5024 - 1.9403i	19.6819 - 2.2103i
19.5024 + 1.9403i	19.6819 + 2.2103i
20.8469	21.0997 + 0.0000i

raízes

 $p(x)$ $q(x)$

CONDICIONAMENTO DE UM PROBLEMA

Condicionamento de um problema

Um problema diz-se **mal condicionado** se for muito sensível a pequenas alterações nos seus dados; caso contrário, diz-se **bem condicionado**.

Nota: O cálculo de zeros de polinómios de grau elevado é, geralmente, um problema mal condicionado, o que significa que a determinação de boas aproximações numéricas para os zeros deste tipo de polinómios é, em geral, um problema difícil.

NÚMERO DE CONDIÇÃO DE UMA FUNÇÃO

- ➡ Seja $\tilde{x}$ um valor aproximado para x com um erro relativo $|\mathcal{R}_{\tilde{x}}| \ll 1$.
- ➡ Seja f uma função continuamente diferenciável numa vizinhança de x (que contém $\tilde{x}$).

Como se “propaga” o erro em x ao cálculo de $f(x)$?

Sejam $y = f(x)$ e $\tilde{y} = f(\tilde{x})$. Pelo teorema do valor médio,

$$y - \tilde{y} = f(x) - f(\tilde{x}) = f'(\xi)(x - \tilde{x}), \quad \xi \in (\min\{x, \tilde{x}\}, \max\{x, \tilde{x}\}).$$

Temos, então

$$|R_{\tilde{y}}| = \left| \frac{y - \tilde{y}}{y} \right| = \left| \frac{f'(\xi)(x - \tilde{x})}{f(x)} \right| = \left| \frac{xf'(\xi)}{f(x)} \right| \cdot \left| \frac{x - \tilde{x}}{x} \right| = \left| \frac{xf'(\xi)}{f(x)} \right| |R_{\tilde{x}}|.$$

Como admitimos que x e $\tilde{x}$ estão próximos, será razoável substituir $f'(\xi)$ por $f'(x)$, tendo-se, então

$$|R_{f(\tilde{x})}| \approx \left| \frac{x f'(x)}{f(x)} \right| |R_{\tilde{x}}|$$

Assim, a quantidade $\left| \frac{x f'(x)}{f(x)} \right|$ é uma medida do condicionamento do cálculo do valor de f em x .

Chama-se **número de condição de f em x** e denota-se por **cond $f(x)$** à quantidade dada por

$$\text{cond } f(x) = \left| \frac{x f'(x)}{f(x)} \right|$$

- ➡ Se **cond $f(x)$** é “pequeno”, o problema de calcular $f(x)$ é **bem condicionado**.
- ➡ Se **cond $f(x)$** é “grande”, o problema de calcular $f(x)$ é **mal condicionado**.

Exemplo:

$$\Rightarrow f(x) = \sqrt{x}$$
$$f'(x) = \frac{1}{2\sqrt{x}}$$
$$\text{cond } f(x) = \frac{1}{2}$$

função bem condicionada para todo x .

$$\Rightarrow f(x) = e^x$$
$$f'(x) = e^x$$
$$\text{cond } f(x) = |x|$$

função mal condicionada para valores de x tais que $|x|$ é “grande”;
bem condicionada para valores de x tais que $|x|$ é “pequeno”.

ESTABILIDADE/INSTABILIDADE DE UM MÉTODO

Diz-se que um método é **instável** se os erros se amplificam no decurso dos cálculos, de forma inaceitável; caso contrário, o método diz-se **estável**.


Exemplo: Duas expressões para a mesma função:

$$f(x) = \frac{1 - \cos^2 x}{x^2} \quad g(x) = \frac{\sin^2 x}{x^2}$$

Os resultados de $\cos x$ e $\sin x$ foram arredondados para 10 a.s.; os restantes cálculos foram efetuados com a precisão do Matlab.



```
>> f=@(x) (1-round(cos(x),10).^2)./x.^2;  
>> g=@(x) round(sin(x),10).^2./x.^2;  
>> [f(5*10^-5) g(5*10^-5)]  
ans =  
0.9599999990612914    0.999999999200000
```



As funções f e g , embora matematicamente equivalentes, são numericamente diferentes!

Nota: O uso de fórmulas que possam provocar cancelamento subtrativo é uma das grandes fontes de instabilidade nos algoritmos.